

El uso del cómputo evolutivo y otros modelos evolutivos en series de tiempo

Flores Gómez Javier Alberto, 423122215@pcpuma.acatlan.unam.mx, UNAM, Facultad de Estudios Superiores Acatlán

ÍNDICE

RESUMEN	2
Palabras Clave	2
ABSTRACT.....	2
KEYWORDS.....	2
INTRODUCCIÓN	3
Contexto	3
Antecedentes	3
Justificación.....	4
Objetivo	4
MATERIAL Y MÉTODOS.....	5
Tipo de la investigación.....	5
Diseño de la investigación.....	5
Población.....	5
Análisis Exploratorio de Datos	5
Métodos para Pronósticos.....	7
RESULTADOS.....	9
Modelo ARIMA	9
Modelo ARMA.....	10
Modelo CE	10
Modelo DECS	11
DISCUSIÓN	12
Uso de la inteligencia artificial generativa	14
REFERENCIAS.....	14

RESUMEN

La optimización es un tema ampliamente utilizado en nuestros días el cual es muy útil en varias áreas del conocimiento. Por otro lado, las series de tiempo han sido un método de predicción bastante utilizado en el ámbito de negocios y economía, sin embargo, aún no han sido completamente exploradas en términos de eficiencia. Los métodos de ARIMA y ARMA son muy comunes y utilizados, mientras que, por otro lado, los algoritmos evolutivos como el Cómputo Evolutivo, DECS o ECOS nos dan una amplia gama de soluciones para el mismo problema, pero con la particularidad de añadir parámetros a nuestras aproximaciones para hacerlas más precisas a lo que buscamos. Por ello, este artículo busca hacer una exploración sobre varios algoritmos genéticos basados en el CE para posteriormente analizar qué métodos (tradicionales o genéticos) son más eficientes en la creación de una serie de tiempo a partir de diagramas, efectividad, eficiencia computacional, entre otros parámetros, y qué mejora puede haber a futuro en los diversos ámbitos de los pronósticos donde se utilicen las series de tiempo como método principal de aproximación.

Palabras Clave

Pronósticos · Series de Tiempo · Cómputo Evolutivo (CE) · Algoritmos Evolutivos (AE) · Modelo de Media Móvil Autorregresiva (ARMA) · Sistema de Computación Dinámico Evolutivo (DECS) · Sistemas Conexionistas Evolutivos (ECOS) · Modelo de Media Móvil Integrada Autorregresiva (ARIMA)

ABSTRACT

Optimization is a widely used topic nowadays, which is very useful in various areas of knowledge. On the other hand, time series have been a frequently employed prediction method in the fields of business and economics; however, they have not yet been fully explored in terms of efficiency. ARIMA and ARMA methods are very common and widely used, while, on the other hand, evolutionary algorithms such as Evolutionary Computation (EC), DECS, or ECOS provide a wide range of solutions for the same problem, but with the added feature of introducing parameters to our approximations to make them more precise according to our needs. Therefore, this article seeks to explore several genetic algorithms based on EC and subsequently analyze which methods (traditional or genetic) are more efficient in the creation of a time series based on diagrams, effectiveness, computational efficiency, among other parameters, and what future improvements can be made in the various fields of forecasting where time series are used as the main method of approximation.

KEYWORDS

Forecasting · Time Series · Evolutionary Computation (EC) · Evolutionary Algorithms (EA) · Autoregressive Moving Average Model (ARMA) · Dynamic Evolutionary Computation System (DECS) · Evolutionary Connectionist Systems (ECOS) · Autoregressive Integrated Moving Average Model (ARIMA)

INTRODUCCIÓN

Contexto

Conforme ha aumentado el uso del análisis de datos en áreas como la medicina, las finanzas, los negocios, la meteorología y el entretenimiento, el análisis por series de tiempo se ha vuelto mucho más importante. Los datos de series temporales son secuencias de mediciones a lo largo del tiempo que describen el comportamiento de los sistemas. Estos comportamientos pueden cambiar con el tiempo debido a eventos externos y/o cambios sistemáticos internos en la dinámica/distribución (Aminikhanghahi & Cook, 2017).

El estudio de las series de tiempo tiene una variedad de puntos a analizar, sin embargo, nos centraremos en dos puntos en concreto: la parte de selección de datos y la ecuación de regresión. Hablando del modelado a nivel estadístico, se sabe que la manera en la que se seleccionan las variables más significativas (las que afectan más al evento que estamos pronosticando) es una fase muy importante y que afecta significativamente a los datos que se obtendrán (Aladag et al., 2014). A su vez, la fase de modelado consiste en desarrollar modelos matemáticos a partir de datos experimentales, lo que implica encontrar simultáneamente tanto la estructura como los parámetros del modelo (Claveria et al., 2019a).

Por otro lado, los Algoritmos Evolutivos (AE) son enfoques de búsqueda basados en la población que están inspirados en los principios de la selección natural y la genética. Para resolver un problema de optimización dado, un AE típicamente comienza con una población de individuos generada aleatoriamente utilizando un esquema de codificación específico del problema. Los individuos luego se someten a operaciones genéticas, es decir, cruce, mutación y selección, para producir una (Tan et al., 2021). Bajo este contexto, podemos plantear la selección de variables como la creación del modelo de series de tiempo como un problema de optimización con el objetivo de utilizar los AE para obtener la mejor alternativa en estos dos puntos del proceso.

Sin embargo, hay un algoritmo evolutivo en concreto el cual trataremos en este artículo; el cómputo evolutivo. El cómputo evolutivo es un campo de la inteligencia artificial que se fundamenta en la teoría de la selección natural para desarrollar algoritmos de búsqueda y optimización. Este algoritmo se basa principalmente en un ciclo de seis pasos, estos son: Obtener la población inicial, crear la Función de Aptitud, Selección, Crossover y Mutación, Reemplazo y Convergencia. Aunque este proceso lo analizaremos más adelante.

Antecedentes

A lo largo de la historia de la estadística se han desarrollado distintos métodos para resolver el mismo problema y para las series de tiempo, ésta no es la excepción. El estudio de la predicción de series temporales comienza con una ecuación de regresión que predice patrones y tendencias futuras (Li et al., 2019). El modelo de media móvil autorregresiva (ARMA) y el modelo de media móvil integrada autorregresiva (ARIMA) muestran que el modelado de predicción de series temporales basado en el método de regresión es cada vez más popular. Como ejemplo de uno de los dos métodos, tenemos el modelo ARIMA; es una técnica que se usa frecuentemente para predecir diversos valores o características. Además de su uso en pronósticos y series de tiempo, los modelos ARIMA sirven para desarrollar distintas metodologías de suavizado exponencial (Safaei et al., 2022). Sin embargo, a pesar de su popularidad, también han aparecido métodos

evolutivos, los cuales se basan principalmente en el cómputo evolutivo, estos métodos (por mencionar algunos) son:

El Sistema de Computación Dinámico Evolutivo (DECS): es un tipo de computación evolutiva que trabaja de forma ininterrumpida, a su vez, su principal característica es adaptar su estructura y funciones conforme el tiempo avanza. Esto ocurre gracias a una interacción constante con su ambiente y con otros sistemas, y se rige por tres factores clave: Un conjunto de parámetros P que evolucionan junto con el sistema, un flujo constante de datos de entrada cuya distribución de probabilidad es impredecible, y, finalmente, un criterio de optimización (racional) que también puede modificarse y que guía al sistema a una mejor evolución (Chen & Lin, 2007). Otro paradigma bastante conocido para modelar procesos en evolución se denomina Sistemas Conexionistas Evolutivos (ECOS). Los ECOS desarrollan su estructura y funcionalidad a lo largo del tiempo a partir de los datos entrantes. Los ECOS también necesitan tener valores de parámetros en evolución y adaptación que respondan a los cambios en los procesos modelados (Chen & Lin, 2007). Los DECS son una vertiente de los ECOS.

Justificación

La optimización y la predicción precisa son fundamentales en la toma de decisiones operativas de cualquier ámbito. Aunque las series de tiempo son herramientas establecidas principalmente por modelos como ARIMA y ARMA, su potencial completo en términos de eficiencia computacional y precisión aún está por explorarse. Es por ello que esta investigación busca abordar una laguna metodológica y teórica en la literatura: la falta de una comparación rigurosa y objetiva entre los métodos tradicionales y las alternativas de AE, en este caso específico trataremos los algoritmos basados en CE. Este estudio proporcionará un marco comparativo que, al evaluar la efectividad, la precisión y la eficiencia computacional de estos métodos, determinará cuál de los enfoques ofrece un pronóstico más acertado. Por otro lado, esta exploración puede continuar con investigaciones sobre la creación de algoritmos genéticos los cuales tengan una mejor efectividad en distintos ámbitos, ya no sólo en el área de los pronósticos solamente, sino que se puede ampliar su uso a otras ramas de las matemáticas.

Objetivo

El objetivo de esta investigación es proponer y evaluar métodos evolutivos, en especial el cómputo evolutivo, para la selección de variables en series de tiempo y para la optimización de la creación de la ecuación de regresión, con el fin de maximizar la precisión de los pronósticos obtenidos, en contraste con los métodos estadísticos tradicionales como lo son los métodos de ARIMA y ARMA. Además, se busca evaluar y proponer la aplicación del Cómputo Evolutivo (CE) y otros modelos evolutivos basados en el CE como el Sistema de Computación Dinámico Evolutivo (DECS) para optimizar las fases críticas del análisis y modelado de series de tiempo.

Para esta investigación, se utilizarán los algoritmos evolutivos (AE) para abordar el desafío de la selección de variables más significativas que afectan el comportamiento de las series temporales, mejorando así la calidad de los datos para el pronóstico. Por otro lado, el CE se utilizará para encontrar simultáneamente la estructura y los parámetros óptimos del modelo matemático (ecuación de regresión). Finalmente, se analizará cómo los sistemas especializados como DECS y CE, con su capacidad de adaptar la estructura y los parámetros a los flujos de datos impredecibles,

superan o complementan a los métodos estadísticos tradicionales (como ARIMA y ARMA) en el pronóstico de series temporales.

MATERIAL Y MÉTODOS

Para cumplir con el objetivo de esta investigación, que es evaluar y comparar la eficiencia de los modelos de series de tiempo tradicionales (ARMA/ARIMA) frente a los algoritmos evolutivos (CE, DECS), se estableció una metodología a través de cuatro fases. Esta metodología comenzó con la selección y preprocesamiento de un conjunto de datos financieros con el fin de realizar un Análisis Exploratorio de Datos (EDA) detallado. Posteriormente, se procedió a aplicar técnicas de optimización evolutiva y estadísticas para la determinación de los parámetros y la estructura de cada modelo. Finalmente, todos los modelos fueron puestos a prueba bajo las mismas condiciones de datos y evaluados mediante métricas de error y criterios de información para asegurar una comparación rigurosa de su efectividad y eficiencia computacional.

Tipo de la investigación

La investigación se clasifica de tipo explicativo y comparativo, enmarcada en el ámbito de la ciencia de datos y la inteligencia artificial. Es explicativa porque busca establecer la relación y el rendimiento entre diferentes metodologías, modelos ARIMA, ARMA y algoritmos evolutivos como CE y DECS, en una tarea; la predicción de series de tiempo. Por otro lado, es comparativa dado que el objetivo principal es contrastar la eficiencia y la precisión de los métodos tradicionales frente a los genéticos, determinando cuál ofrece una solución óptima para el problema del pronóstico.

Diseño de la investigación

El diseño de la investigación es de naturaleza experimental con un enfoque cuantitativo, es decir, los diferentes modelos se aplican al mismo conjunto de datos bajo condiciones controladas, permitiendo la manipulación y la evaluación objetiva de los resultados. Específicamente, se emplea un diseño de validación de modelos donde los datos históricos se dividen en un conjunto de entrenamiento y un conjunto de prueba para calcular las métricas de error y comparar la capacidad predictiva de cada modelo.

Población

Para este caso en concreto, el análisis se basó en el conjunto de datos de series de tiempo conocido como "Time Series starter dataset", accesible a través de la plataforma Kaggle. Este dataset fue publicado originalmente por podsyp (2018). Este conjunto de datos contiene datos financieros de ventas sobre una empresa simulada, las principales columnas describen el periodo de tiempo, las ganancias en USD, la cantidad de ventas y el costo promedio. Aunque cabe recalcar que para todos los métodos se utilizó Python 3.12.12 y mínimamente las librerías de Pandas, Numpy y Matplotlib dentro de este lenguaje de programación. A continuación, se describirá nuestro Análisis Exploratorio de Datos del dataset mencionado con el fin de entender de una mejor manera lo que se realizó durante los distintos pronósticos.

Análisis Exploratorio de Datos

Inicialmente se analizó el dataset a través de un gráfico de líneas de valor mensual, este gráfico describe cómo cambian las variables a lo largo de la columna periodo. En particular, los siguientes diagramas demuestran que las ganancias aumentaron cada año, sin embargo, hay una gran

volatilidad, por otro lado, la cantidad de ventas y el costo promedio se mantienen estables y casi no son visibles, sin embargo, la nómina anual mantiene una tendencia de crecimiento más estable y gradual. Nótese que el gráfico se dividió en cada columna para que se puedan apreciar todos los datos.



Figura 1. Line Plot de valor mensual del dataset empleado

Otro gráfico importante a analizar es el gráfico de barras apiladas, para este caso, este gráfico demuestra que, para nuestros datos, la columna de ganancias y la de nómina manejan una gran cantidad monetaria, en ellas se observa que hubo una gran contracción en ambos entre los periodos de 2019 y 2022.

Gráfico de Barras Apiladas





Figura 2. Stacked Plot del dataset a tratar

En base a esta información, sólo se analizará la correlación entre los datos para ver si pudo afectar o no a los resultados obtenidos posteriormente con cada método, con lo que la

Figura 3. Matriz de Correlación entre las variables del dataset muestra la correlación entre nuestros datos y se puede concluir que la cantidad de ventas tiene una gran relación con las



ganancias, y esto es lógico, por lo que se deja pasar, por otro lado, las demás relaciones son estables y no se consideran un problema para los modelos que se utilizaron.

Figura 3. Matriz de Correlación entre las variables del dataset

Una vez hechos estos análisis, se llegó a la conclusión de que los datos no poseen ningún sesgo o perturbación las cuales afecten al funcionamiento de los métodos genéticos y clásicos que se utilizaron, por lo que a continuación se define cada uno de estos.

Métodos para Pronósticos

A. ARMA

El modelo de media móvil autorregresiva (ARMA) de orden (p,q) está definido por la siguiente ecuación:

$$x_t = c + \sum_{i=1}^p \varphi_i x_{t-i} + \varepsilon_t + \sum_{i=0}^q \theta_i \varepsilon_{t-i} \quad (1)$$

Donde x_t es la variable estacionaria que se busca predecir, c es una constante arbitraria, φ_i son los coeficientes de correlación p-ésimos mientras que ε_t son los residuales con distribución normal estándar, finalmente θ_i son los q-ésimos pesos aplicados a los valores a priori de la serie de tiempo.

En base a esta ecuación y a la librería statsmodels de Python, se ejecutó correctamente este modelo.

B. ARIMA

El modelo de media móvil integrada autorregresiva (ARIMA) es un modelo generalizado del modelo de media móvil autorregresiva (ARMA) que combina procesos autorregresivos (AR) y de media móvil (MA) y construye un modelo compuesto de la serie temporal (Siarni-Namini et al., 2018). Un modelo ARIMA de orden (p,d,q) se obtiene con la siguiente ecuación:

$$y_t = c + \sum_{i=1}^p \varphi_i y_{t-i} + \varepsilon_t + \sum_{i=0}^q \theta_i \varepsilon_{t-i} \quad (2)$$

Donde se mantienen los mismos parámetros que para el método ARMA, sin embargo, y_t se define como una serie diferenciada de la siguiente manera.

$$y_t = (1 - L)^d x_t \quad (3)$$

Donde L es el operador de retardo y d es el número de veces que se diferencia la serie. Para la implementación de este método, se utilizó la librería pmdarima en Python.

C. CE

El cómputo evolutivo (CE) es una técnica de búsqueda en computación blanda para la resolución de problemas. Los programas de CE, con estructura de árbol, evolucionan mediante operadores genéticos para la aproximación de modelos (Claveria et al., 2019a). Para este caso, utilizaremos el algoritmo ICLA-EC cuyas siglas significan Autómata de Aprendizaje Celular Irregular de Cómputo Evolutivo, el cual fue definido en el artículo “A new irregular cellular learning automata-based evolutionary computation for time series link prediction in social networks” bajo el siguiente algoritmo:

Algorithm 1: procedure of ICLA-EC	
1.	<i>Initialize</i>
2.	<i>While</i> not a predetermined criterion is met <i>do</i>
3.	<i>For</i> each vertex v_i in the ICLA-EC <i>do in parallel</i>
4.	Generate a new genome according to probability vector
5.	Evaluate the new genome based on fitness function
6.	<i>If</i> $fitness(new\ genome) > fitness(old\ genome)$ <i>then</i>
7.	The new genome replaces the genome of the vertex
8.	<i>End if</i>
9.	Select <i>several</i> vertices based on their fitness from the neighbors of vertex
10.	Generate the reinforcement signal vector
11.	Update LA of vertex based on reinforcement signal and learning algorithm
12.	<i>End parallel for</i>
13.	<i>End while</i>

Figura 4. Algoritmo ICLA-EC (Khaksar Manshad et al., 2021)

D. DECS

El sistema de computación dinámica evolutiva (DECS) utiliza un motor de inferencia difusa de tipo Takagi-Sugeno (Chia-Feng Juang, 2002). El motor de inferencia de DECS se compone de m reglas difusas, las cuales son descritas en el artículo “Dynamic parameter optimization of evolutionary computation for on-line prediction of time series with changing dynamics” (Chen & Lin, 2007). Sin embargo, se resume este método a través de los siguientes pasos:

- I. Codificación.
- II. Inicialización.
- III. Evaluación del modelo difuso.
- IV. Cálculo de valores.

- V. Reproducción.
- VI. Cruza.
- VII. Mutación.
- VIII. Repetición.

Los cuales son una versión que adapta el algoritmo del CE a un modelo difuso.


Finalmente, cabe recalcar que las comparaciones no sólo se basaron en los pronósticos obtenidos para el modelo en este caso de las ganancias de la empresa descrita por el dataset, sino que también se obtuvieron los resultados a través de métodos de distancias, principalmente el Error Cuadrático Medio (ECM) y el Error Porcentual Absoluto Medio (MAPE), los cuales se describen en el siguiente apartado.

RESULTADOS

Después de un análisis de los métodos utilizados cabe aclarar que los algoritmos genéticos utilizados realizaron una aproximación para encontrar los mejores coeficientes para crear un modelo ARIMA, esto ya que después de un análisis de autocorrelación se observó que el modelo ARMA no fue efectivo, o al menos no lo suficiente, ya que la serie no era estacionaria, por lo que se necesitó integrar el modelo, cosa la cual el modelo ARMA no puede realizar, por lo que sus resultados están sesgados. A continuación, se detalla el procedimiento y los resultados obtenidos por cada método.

Modelo ARIMA

Este método se realizó inicialmente con un análisis en las gráficas de autocorrelación de la serie



las cuales se muestran en la Figura 5. Graficas de autocorrelación de la serie.

Figura 5. Graficas de autocorrelación de la serie.

El modelo ARIMA óptimo encontrado por el proceso de optimización fue el ARIMA(4, 2, 1). Como se observa en el resumen, todos los coeficientes AR tienen valores $P > |z|$ muy bajos, indicando que son estadísticamente significativos en la explicación de la serie.

Este modelo fue eficiente en la captura de la complejidad de la serie, pues la desviación estándar de los coeficientes del modelo resultó ser muy baja, lo que implica una gran precisión en la estimación de éstos. Sin embargo, la varianza del error del modelo se disparó a valores muy altos;

este valor sugiere que, aunque los parámetros del modelo están bien estimados, la serie es muy volátil.

SARIMAX Results						
=====						
Dep. Variable:	Revenue	No. Observations:	57			
Model:	ARIMA(4, 2, 1)	Log Likelihood	-1090.857			
Date:	Tue, 18 Nov 2025	AIC	2193.714			
Time:	17:44:23	BIC	2205.758			
Sample:	0	HQIC	2198.372			
	- 57					
Covariance Type:	opg					
=====						
	coef	std err	z	P> z	[0.025	0.975]

ar.L1	-2.6563	0.255	-10.435	0.000	-3.155	-2.157
ar.L2	-3.4398	0.536	-6.421	0.000	-4.490	-2.390
ar.L3	-2.4142	0.518	-4.657	0.000	-3.430	-1.398
ar.L4	-0.7878	0.262	-3.004	0.003	-1.302	-0.274
ma.L1	-0.9422	0.528	-1.784	0.074	-1.977	0.093
sigma2	1.679e+16	1.81e-17	9.3e+32	0.000	1.68e+16	1.68e+16
=====						
Ljung-Box (L1) (Q):	18.65	Jarque-Bera (JB):	1.25			
Prob(Q):	0.00	Prob(JB):	0.54			
Heteroskedasticity (H):	2.09	Skew:	0.21			
Prob(H) (two-sided):	0.13	Kurtosis:	2.39			
=====						

Figura 6. Modelo ARIMA.

Modelo ARMA

Como se mencionó anteriormente, el modelo ARMA tuvo un error durante el planteamiento, este error introduce un sesgo inicial y hace que las estadísticas de error, como la varianza y el P(Q) de Ljung-Box sean menos fiables. A pesar de este sesgo fundamental, el modelo ARMA(3, 1) muestra coeficientes con desviaciones estándar muy bajas, indicando que los valores estimados para los componentes son muy precisos dentro del modelo. Los problemas de ajuste se observan claramente en la varianza, la cual es extremadamente alta y en la prueba Ljung-Box, cuyo valor rechaza la hipótesis nula de que los residuos son ruido blanco. Esto significa que el modelo no capturó la estructura de la serie de manera efectiva. A continuación, se observa el modelo ARMA.

SARIMAX Results						
=====						
Dep. Variable:	Revenue	No. Observations:	57			
Model:	ARIMA(3, 0, 1)	Log Likelihood	-1102.982			
Date:	Tue, 18 Nov 2025	AIC	2217.964			
Time:	17:54:40	BIC	2230.222			
Sample:	0	HQIC	2222.728			
	- 57					
Covariance Type:	opg					
=====						
	coef	std err	z	P> z	[0.025	0.975]

const	-1.181e+06	1.15e-07	-1.03e+13	0.000	-1.18e+06	-1.18e+06
ar.L1	-1.8636	0.177	-10.535	0.000	-2.210	-1.517
ar.L2	-1.7716	0.235	-7.524	0.000	-2.233	-1.310
ar.L3	-0.7599	0.171	-4.434	0.000	-1.096	-0.424
ma.L1	-0.6762	0.341	-1.983	0.047	-1.345	-0.008
sigma2	5.406e+15	2.99e-17	1.81e+32	0.000	5.41e+15	5.41e+15
=====						
Ljung-Box (L1) (Q):	21.78	Jarque-Bera (JB):	4.37			
Prob(Q):	0.00	Prob(JB):	0.11			
Heteroskedasticity (H):	1.91	Skew:	0.61			
Prob(H) (two-sided):	0.17	Kurtosis:	2.40			

Figura 7. Modelo ARMA

Modelo CE

Este modelo se realizó a partir de los estándares descritos en el artículo (Storn & Price, 1997), tiene como principal ventaja explorar eficientemente el espacio de parámetros p, d, q para minimizar el

error predictivo. Este modelo presenta características superiores a los modelos anteriores en términos de diagnóstico. Sus coeficientes son altamente y sus desviaciones estándar son muy bajas, confirmando la estabilidad de los parámetros. Esto se puede observar en la Figura 8. Modelo CE.

SARIMAX Results						
=====						
Dep. Variable:	Revenue	No. Observations:	64			
Model:	ARIMA(2, 1, 0)	Log Likelihood	-1081.482			
Date:	Thu, 20 Nov 2025	AIC	2168.964			
Time:	04:34:58	BIC	2175.394			
Sample:	0	HQIC	2171.493			
	- 64					
Covariance Type:	opg					
=====						
	coef	std err	z	P> z	[0.025	0.975]

ar.L1	-0.7748	0.076	-10.218	0.000	-0.923	-0.626
ar.L2	-0.6759	0.088	-7.658	0.000	-0.849	-0.503
sigma2	4.316e+13	2.47e-16	1.74e+29	0.000	4.32e+13	4.32e+13
=====						
Ljung-Box (L1) (Q):		1.02	Jarque-Bera (JB):		0.92	
Prob(Q):		0.31	Prob(JB):		0.63	
Heteroskedasticity (H):		1.16	Skew:		0.13	
Prob(H) (two-sided):		0.74	Kurtosis:		2.47	
=====						

Figura 8. Modelo CE.

Modelo DECS

Finalmente, este modelo se realizó bajo la sugerencia hecha en el artículo (Šourek & Pošík, 2016), se partió con un tamaño de ventana relativamente bajo debido a la cantidad de datos que se tenía en la serie, sin embargo, esto no impidió que el modelo funcionase correctamente y arrojase el siguiente modelo ARIMA el cual obtuvo resultados similares al CE con la particularidad de que se tienen más coeficientes para el modelo, sin embargo, disminuyó notoriamente la desviaciones de éstos y cambiaron drásticamente los valores de las pruebas de hipótesis, Nótese que a pesar de haber partido con los mismos componentes que ARIMA, sus coeficientes y pruebas fueron distintas.

SARIMAX Results						
=====						
Dep. Variable:	Revenue		No. Observations:		64	
Model:	ARIMA(4, 2, 1)		Log Likelihood		-1064.542	
Date:	Thu, 20 Nov 2025		AIC		2141.083	
Time:	04:59:41		BIC		2153.846	
Sample:	0		HQIC		2146.094	
	- 64					
Covariance Type:	opg					
=====						
	coef	std err	z	P> z	[0.025	0.975]

ar.L1	-0.5580	0.164	-3.404	0.001	-0.879	-0.237
ar.L2	-0.4714	0.218	-2.160	0.031	-0.899	-0.044
ar.L3	0.2850	0.203	1.405	0.160	-0.113	0.683
ar.L4	-0.0227	0.135	-0.168	0.866	-0.286	0.241
ma.L1	-0.9862	0.215	-4.595	0.000	-1.407	-0.566
sigma2	5.464e+13	3.26e-15	1.67e+28	0.000	5.46e+13	5.46e+13
=====						
Ljung-Box (L1) (Q):			0.12	Jarque-Bera (JB):	1.23	
Prob(Q):			0.73	Prob(JB):	0.54	
Heteroskedasticity (H):			1.17	Skew:	0.01	
Prob(H) (two-sided):			0.72	Kurtosis:	2.31	

Figura 9. Modelo DECS

Con esto se obtienen datos sumamente interesantes que, a grandes rasgos, pueden dejar mejor parados a los modelos genéticos, sin embargo, hay que tener en cuenta que el modelo ARMA y ARIMA se hacen por un análisis previo de una persona, por lo que puede tender a tener ciertos

errores, en el siguiente apartado, hacemos un análisis a profundidad de lo mencionado y se comparan los modelos obtenidos.

DISCUSIÓN

En este artículo se analizaron distintos métodos para la generación de un modelo de predicción para series de tiempo tomando como base el modelo ARIMA, sin embargo, esto no afectó a los algoritmos genéticos, incluso en el Cuadro 1. Medidas de error en los modelos. Se puede observar que los modelos genéticos están muy dispersos entre ellos, siendo que el CE fue el que menos ECM obtuvo, lo que quiere decir que fue el modelo con menor error absoluto en comparación con el conjunto de datos de prueba, por otro lado, el modelo con el menor MAPE fue el ARMA, lo que quiere decir que es el modelo con más probabilidad de acertar en un caso real a la hora de predecir datos, aunque éste tiene una gran desviación en estos mismos, ocasionando que el error haya sido mayor.

Modelo utilizado	ECM	MAPE (%)
ARIMA	675.172597	80.542414
ARMA	121.114055	23.454825
CE	95.447990	29.741153
DECS	675.172597	80.542414

Cuadro 1. Medidas de error en los modelos.

Por otro lado, la gráfica de pronósticos vs valores reales, apunta a que el modelo de CE obtiene valores acertados a los que están en el conjunto de prueba, con lo que es mejor para predecir en comparación con los demás modelos, el modelo ARMA logró acercarse un poco, sin embargo, no fue más eficiente que el ya mencionado.




Figura 10. Gráfica Actual vs Forecasts.

Con esto visto, se refuerza la hipótesis mencionada en el artículo (Bian et al., 2025) el cual menciona que los algoritmos genéticos son más eficaces que los algoritmos más comunes en el

ámbito de predicciones, pero en contraparte, los métodos genéticos consumen mucha más memoria y tiempo que los demás. Por otro lado, también se puede notar que la no estacionariedad se puede observar en la gráfica, se nota como los dos modelos que no diferenciaron el modelo, tienen una desviación muy grande y es por ello que no lo pueden predecir correctamente, mientras que los modelos, que asumieron una tendencia en los datos, obtuvieron resultados más acertados.

Por otro lado, como propusieron (Siami-Namini et al., 2018), los algoritmos que utilizan algún tipo de inteligencia artificial para predecir e identificar patrones suelen tener errores de cálculo cuando se utilizan muy pocas generaciones, como fue el caso de esta investigación, se utilizaron apenas 50 generaciones en el CE, esto debido al tamaño de la investigación, sin embargo, esto puede propiciar errores como el atascamiento en un punto muerto o el aumento exponencial de la volatilidad del modelo como se pudo observar con el modelo DECS, el cual tuvo una diferencia notoria en comparación a los modelos tradicionales ya que este modelo no funciona extraordinariamente bien con conjuntos de datos pequeños o con muy poco tiempo de ejecución en sus generaciones. El artículo que propone el modelo DECS (Šourek & Pošík, 2016) establece que este sistema requiere de datos y variables heurísticas, cosa que no sucede para modelos económicos, como fue el caso de este estudio, es por ello que no es recomendable utilizar este sistema de aprendizaje para predicciones fuera reglas confusas, ya que éstas tienden a ser más subjetivas y es algo que tanto el modelo ARIMA como el ARMA no pueden realizar eficazmente.

Otro punto que cabe recalcar en este análisis es el sobreajuste que tuvieron los modelos, los cuales se miden a través de los coeficientes Criterio de Información de Akaike (AIC) y Criterio de Información Bayesiano (BIC), esta información, como se describe en el artículo (Chakrabarti & Ghosh, 2011), determina si el modelo es el óptimo para el análisis y si el modelo funciona para la predicción de observaciones futuras respectivamente. En el Cuadro 2. Comparaciones de Criterios en los modelos. se observa lo mencionado.

Modelo	AIC	BIC
ARIMA	2193.714	2205.758
ARMA	2217.964	2230.222
CE	2168.964	2175.394
DECS	2193.714	2205.758

Cuadro 2. Comparaciones de Criterios en los modelos.

Con estos datos se observan que, objetivamente, el modelo CE es el mejor para este problema ya que tiene el AIC más bajo, a su vez, podemos ver que el modelo CE también es el mejor para la predicción de valores como se visualizó en la anterior gráfica. Con esto se refuerza aún más la conclusión a la que se llegó en (Bian et al., 2025), la cual establece que el CE original es la mejor alternativa para la predicción de valores.

En conclusión, el Cómputo Evolutivo no solo validó la hipótesis de que los algoritmos genéticos son más eficaces para la optimización de parámetros, como sostienen (Tan et al., 2021), sino que también seleccionó un modelo que es superior en robustez, simplicidad (según AIC/BIC) y precisión absoluta (ECM) para la predicción de la serie de tiempo analizada.

Por otro lado, las limitaciones de los modelos genéticos se pueden observar en la capacidad de predicción que tienen para datos pequeños y para complejidades pequeñas para estos casos es mejor usar un modelo ARIMA o ARMA como mantiene (Barandas et al., 2020). Sin embargo,

valdría la pena analizar este tipo de diferencias con más cantidades de datos y con modelos más heurísticos o alejados del área económica, ya que estos datos son nicho como se menciona en (Claveria et al., 2019b) y afectan a la predicción heurística como lo hacen los modelos ARMA y DECS.

Uso de la inteligencia artificial generativa

Para la generación de los apartados de contexto y justificación dentro de la introducción y para la corrección ortográfica y gramatical del apartado de Material y Métodos, se empleó el modelo de lenguaje de gran tamaño Gemini (Google, 2024) con el objetivo de mejorar la redacción sin afectar el contenido sustancial. El texto generado fue posteriormente revisado, editado y verificado por el autor, el cual asume la responsabilidad por el contenido final del artículo.

REFERENCIAS

- Aladag, C. H., Yolcu, U., Egrioglu, E., & Bas, E. (2014). Fuzzy lagged variable selection in fuzzy time series with genetic algorithms. *Applied Soft Computing*, 22, 465-473. <https://doi.org/10.1016/j.asoc.2014.03.028>
- Aminikhanghahi, S., & Cook, D. J. (2017). A survey of methods for time series change point detection. *Knowledge and Information Systems*, 51(2), 339-367. <https://doi.org/10.1007/s10115-016-0987-z>
- Barandas, M., Folgado, D., Fernandes, L., Santos, S., Abreu, M., Bota, P., Liu, H., Schultz, T., & Gamboa, H. (2020). TSFEL: Time Series Feature Extraction Library. *SoftwareX*, 11, 100456. <https://doi.org/10.1016/j.softx.2020.100456>
- Bian, K., Zhang, J., Han, H., Zhou, J., Sun, Y., & Cheng, S. (2025). Learning-infused optimization for evolutionary computation. *Swarm and Evolutionary Computation*, 95, 101930. <https://doi.org/10.1016/j.swevo.2025.101930>
- Chakrabarti, A., & Ghosh, J. K. (2011). AIC, BIC and Recent Advances in Model Selection. En *Philosophy of Statistics* (pp. 583-605). Elsevier. <https://doi.org/10.1016/B978-0-444-51862-0.50018-6>
- Chen, Y. M., & Lin, C.-T. (2007). Dynamic parameter optimization of evolutionary computation for on-line prediction of time series with changing dynamics. *Applied Soft Computing*, 7(4), 1170-1176. <https://doi.org/10.1016/j.asoc.2006.01.004>
- Chia-Feng Juang. (2002). A TSK-type recurrent fuzzy network for dynamic systems processing by neural network and genetic algorithms. *IEEE Transactions on Fuzzy Systems*, 10(2), 155-170. <https://doi.org/10.1109/91.995118>
- Claveria, O., Monte, E., & Torra, S. (2019a). Evolutionary Computation for Macroeconomic Forecasting. *Computational Economics*, 53(2), 833-849. <https://doi.org/10.1007/s10614-017-9767-4>

- Claveria, O., Monte, E., & Torra, S. (2019b). Evolutionary Computation for Macroeconomic Forecasting. *Computational Economics*, 53(2), 833-849. <https://doi.org/10.1007/s10614-017-9767-4>
- Khaksar Manshad, M., Meybodi, M. R., & Salajegheh, A. (2021). A new irregular cellular learning automata-based evolutionary computation for time series link prediction in social networks. *Applied Intelligence*, 51(1), 71-84. <https://doi.org/10.1007/s10489-020-01685-5>
- Li, Y., Zhu, Z., Kong, D., Han, H., & Zhao, Y. (2019). EA-LSTM: Evolutionary attention-based LSTM for time series prediction. *Knowledge-Based Systems*, 181, 104785. <https://doi.org/10.1016/j.knosys.2019.05.028>
- Safaei, S., Ghasemi, P., Goodarzian, F., & Momenitabar, M. (2022). Designing a new multi-echelon multi-period closed-loop supply chain network by forecasting demand using time series model: A genetic algorithm. *Environmental Science and Pollution Research*, 29(53), 79754-79768. <https://doi.org/10.1007/s11356-022-19341-5>
- Siarni-Namini, S., Tavakoli, N., & Siarni Namin, A. (2018). A Comparison of ARIMA and LSTM in Forecasting Time Series. *2018 17th IEEE International Conference on Machine Learning and Applications (ICMLA)*, 1394-1401. <https://doi.org/10.1109/ICMLA.2018.00227>
- Šourek, G., & Pošík, P. (2016). Dynamic system modeling of evolutionary algorithms. *ACM SIGAPP Applied Computing Review*, 15(4), 19-30. <https://doi.org/10.1145/2893706.2893708>
- Storn, R., & Price, K. (1997). Differential Evolution – A Simple and Efficient Heuristic for global Optimization over Continuous Spaces. *Journal of Global Optimization*, 11(4), 341-359. <https://doi.org/10.1023/A:1008202821328>
- Tan, K. C., Feng, L., & Jiang, M. (2021). Evolutionary Transfer Optimization—A New Frontier in Evolutionary Computation Research. *IEEE Computational Intelligence Magazine*, 16(1), 22-33. <https://doi.org/10.1109/MCI.2020.3039066>
- podsys. (2018). Time Series starter dataset [Conjunto de datos]. Kaggle. <https://www.kaggle.com/datasets/podsys/time-series-starter-dataset>